

Kaggriculture 农场博弈 Agent 战役 II

评估可信度重建与一次性确认报告

m3-redocument 审计修订版 | 数据源: workspace/metrics.json

1 摘要

本报告替代旧 m3-polish 结论, 以候选身份冻结、开发/确认种子隔离、AB/BA 双座位、异常 fail-closed、正式 export 原子发布和一次性独立 holdout 组成证据链。冻结候选 SHA-256 为 7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a 该身份通过开发门后用于唯一已发布且未失效的 holdout。来源键: metrics.software.frozen_candidate_identity 来源键: metrics.software.holdout_run_status 开发门完成 32 局, 战绩 31W-1L-0T 策略修复定向测试 35/35 通过。来源键: metrics.software.development_gate_summary 来源键: metrics.software.strategy_repair_test_summary

正式全矩阵预期/实际均为 576/576, AB/BA 为 288/288, 缺失镜像 0, 异常局 0。来源键: metrics.software.holdout_schedule 来源键: metrics.software.holdout_seat_split 来源键: metrics.software.holdout_abnormal_summary

冻结候选在确认子集共 128 局, 战绩 119W-9L-0T, score 0.929688, Wilson 区间 [0.8718, 0.9626]。以每个 (opponent, seed) 的 AB/BA 成对得分为单位, 64 个单位的估计为 0.929688, Student-t 区间 [0.867281, 0.992094]。来源键: metrics.software.confirmatory_overall_record 来源键: metrics.software.confirmatory_order_independent_statistics

这些结果仅描述本地官方引擎和既定对手池。线上指标只以真实提交证据回填 (对局 3、skill rating 488.9 与反馈台账 1W-2L), 不由本地结果代填。来源键: metrics.software.unmeasured.online_ladder_games 来源键: metrics.software.unmeasured.online_skill_rating 来源键: metrics.software.unmeasured.online_feedback_calibration

2 战役定位与范围

2.1 交付定位

本轮目标不是继续追逐单一开发集分数, 而是重建可审计评估流程并为一个冻结候选形成一次性确认记录。可交付对象包括 stdlib-only bot、冻结身份、完整开发门、已发布正式 export、确认性统计、本报告与 SOP v3。账号操作、线上提交和最终版本选择仍由队伍人工执行。

2.2 证据边界

确认结果绑定候选 7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a, 且 holdout 运行前、中、后的哈希一致性判定为 true。来源键: metrics.software.m2b_candidate_sha256 来源键: metrics.software.holdout_candidate_hash_match

holdout 种子现已公开, 清单哈希为 68292287a9b8254538f312fb6e3d1991ce215ca2ac2a4e4b0ecc51a6ddbdc93a。公开后的这些种子不得再用于新的独立 holdout; 任何策略或候选字节变化都必须冻结新身份并使用新的独立确认种子。来源键: metrics.software.holdout_seed_manifest 来源键: metrics.software.holdout_protocol

历史披露(仅此一处): 1500.8 / 36-0 属于固定 p0; 复用开发种子; 顺序敏感 Elo; 非确认性; 不可外推线上。该记录仅用于说明审计为何重开, 不参与本报告主结论。来源键: metrics.software.m2_elo_ratings_full_pool

2.3 禁止外推

本报告不把本地 holdout 等同于线上对手分布, 不对竞赛名次、奖项结果或线上能力作结论。LLM 真实 A/B 未发生, 对应值保持 null 预算闸真实触发值保持 null。来源键: metrics.software.unmeasured.llm_ab_win_rate 来源键: metrics.software.unmeasured.llm_ab_budget_gate_hits

3 方法与选型

3.1 候选身份锁定

候选路径、SHA-256、git ref 与冻结清单由 frozen_candidate_identity 给出。开发门候选 SHA 与冻结 SHA 均为 7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a, holdout 的 frozen/before/after 三个值均由正式 export 记录, 一致性判定为 true。来源键: metrics.software.development_gate_summary 来源键: metrics.software.frozen_candidate_identity 来源键: metrics.software.holdout_candidate_hash_match

3.2 种子域与一次性规则

正式协议记录 one_time=true, candidate_change_invalidates=true, seed_count=8 holdout 与历史已用种子的交集计数为 0, 隔离判定为 true。来源键: metrics.software.holdout_protocol 来源键: metrics.software.holdout_seed_domain_isolation

种子只有在运行完成后公开。当前公开清单是既有证据的一部分, 不再具备新独立确认集资格。后续若策略变化, 只能建立新候选、新清单和新的的一次性确认记录。

3.3 AB/BA 与完整矩阵

每个候选-对手-种子组合均以 AB/BA 镜像执行。正式矩阵实际局数为 576, 其中 AB 288 局、BA 288 局, 缺失镜像 0。来源键: metrics.software.holdout_schedule 来源键: metrics.software.holdout_seat_split

3.4 异常关闭与原子发布

生产契约检查判定为 true 它覆盖缺失必测对手、单座位、INVALID、畸形 tie、种子域不符和 exploratory 冒充正式 PASS 的拒绝路径。来源键: metrics.software.m2a_gate_contract_check_pass

export 安全检查判定为 true 正式结果只在 schema、语义和跨字段验证完成后发布, 开发或失败产物不得覆盖正式 export。来源键: metrics.software.m2a_export_safety_check_pass

4 四阶段波次执行记录

4.1 m2a: 评估器加固

完整软件测试通过 128/128 生产 gate 契约与 export 安全检查分别为 true 和 true。修复前的一次开发门已明确 invalidated=true, 不再作为合入证据。来源键: metrics.software.m2a_tests_passed 来源键: metrics.software.m2a_tests_total 来源键: metrics.software.m2a_gate_contract_check_pass 来源键: metrics.software.m2a_export_safety_check_pass 来源键: metrics.software.m2a_complete_gate_invalidated

4.2 m2b: 策略修复与冻结

定向策略/契约测试通过 35/35, failed=0。检查项记录末日零资本支出=true、末日现收处置=true、购买观察确认=true、shed 库存预留=true、严格正数量=true。来源键: metrics.software.strategy_repair_test_summary 来源键: metrics.software.strategy_repair_checks

完整开发门 expected/actual 为 32/32, AB/BA 为 16/16, 异常 0, 战绩 31W-1L-0T, formal_pass=true。通过后冻结候选 SHA-256 为 7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a。来源键: metrics.software.development_gate_summary 来源键: metrics.software.frozen_candidate_identity

4.3 m2c: 一次性独立 holdout

唯一记录的 attempt index 为 1, 状态 published, published=true, invalidated=false。正式全矩阵 expected/actual 为 576/576, 完整性合取判定为 true。来源键:metrics.software.holdout_run_status 来源键:metrics.software.holdout_schedule 来源键:metrics.software.holdout_integrity_pass

本阶段只发布既有 attempt 的结果。验证动作可以重读并校验正式文件, 但不得重跑、重抽或替换该 holdout。

4.4 m3: 文档重生成

本版只消费合并后的 metrics, 将旧开发 Elo 降为历史披露, 将主结论改为逐对 W/L/T、座位拆分、Wilson 区间和顺序无关成对统计。线上与真实 LLM A/B 的未测键继续显示 null。

5 实测结果

5.1 身份与完整性

审计项	结果
冻结候选 SHA-256	7c482921857562e6b7cd58a3ac4bde35 8981c180cc233ad3913948e5fcafa66a
holdout 哈希一致	true
发布 attempt	index=1 status=published invalidated=false
完整矩阵 expected/actual	576 / 576
AB/BA; missing mirrors	288 / 288 0
异常局; integrity	0 true

来源键: metrics.software.frozen_candidate_identity 来源键: metrics.software.holdout_candidate_hash_match 来源键: metrics.software.holdout_run_status 来源键:metrics.software.holdout_schedule 来源键:metrics.software.holdout_seat_split 来源键:metrics.software.holdout_abnormal_summary 来源键:metrics.software.holdout_integrity_pass

5.2 总体与区间

冻结候选确认战绩为 119W-9L-0T, games=128, score=0.929688。来源键:metrics.software.confirmatory_overall_record

统计量	估计	区间
逐局 score 的 Wilson 区间	0.929688	[0.8718, 0.9626]
每 (opponent, seed) AB/BA 成对均值; unit=64	0.929688	[0.867281, 0.992094]

来源键:metrics.software.confirmatory_wilson_intervals 来源键:metrics.software.confirmatory_order_independent_statistics

Wilson 方法为 Wilson score; tie=0.5, confidence=0.95 成对统计方法为 mean per-(opponent,seed) AB/BA score; Student-t 95% CI, order_independent=true, fit_status=ok。来源键:metrics.software.confirmatory_wilson_intervals 来源键:metrics.software.confirmatory_order_independent_statistics

5.3 对手记录

opponent	games	W-L-T	score	Wilson interval
cow_baron	16	10W-6L-0T	0.625	[0.3864, 0.8152]
melon_hoarder	16	13W-3L-0T	0.8125	[0.5699, 0.9341]
expansionist	16	16W-0L-0T	1	[0.8064, 1]

opponent	games	W-L-T	score	Wilson interval
baseline_wheat	16	16W-0L-0T	1	[0.8064, 1]
greedy_carrot	16	16W-0L-0T	1	[0.8064, 1]
starter	16	16W-0L-0T	1	[0.8064, 1]
random	16	16W-0L-0T	1	[0.8064, 1]
pass	16	16W-0L-0T	1	[0.8064, 1]

来源键: metrics.software.confirmatory_pair_records

5.4 座位记录

seat	games	W-L-T	score	Wilson interval
AB	64	60W-4L-0T	0.9375	[0.85, 0.9754]
BA	64	59W-5L-0T	0.921875	[0.8298, 0.9662]

来源键: metrics.software.confirmatory_seat_records

5.5 线上反馈与未回填项

指标	值	含义
线上对局	3	依赖真实线上提交, 已按第一轮实测回填
线上 skill rating	488.9	依赖真实线上提交与平台计分
线上反馈校准	1W-2L	第一轮失败模式台账见 exports/online/
最终提交 commits	null	人工终交锁定尚未回填

来源键: metrics.software.unmeasured.online_ladder_games 来源键: metrics.software.unmeasured.online_skill_rating 来源键: metrics.software.unmeasured.online_feedback_calibration 来源键: metrics.software.unmeasured.final_submission_commits

6 合规与人机分工

6.1 合规边界

提交 bot 保持离线、自包含和 stdlib-only; 外部 LLM 不是线上运行依赖。正式结论只消费身份匹配、完整矩阵、零异常且已发布的 export。账号报名、提交、Validation Episode 检查、提交额度管理和最终锁定均由队伍人工执行, 本报告不把流程约束写成已完成事实。

6.2 人机分工概要

AI 辅助完成评估器加固、策略修复、测试与本地证据生成, 并依据 metrics 重写文档。人工负责规则复核、候选裁决、Kaggle 账号操作、线上反馈解释、是否形成新候选以及最终签字。详细留痕见附录 A。

7 遗留与可复用资产

7.1 局限

- 当前确认集对手来自既定本地池, 不能覆盖未知线上策略分布。
- holdout 种子已公开, 只能复核既有证据, 不得再作为新独立确认集。来源键: metrics.software.holdout_seed_manifest
- 任何策略变化都会使旧候选身份与确认结果不再适用于新候选。来源键: metrics.software.holdout_protocol

- 线上指标按第一轮真实提交证据回填，但样本极小且对手分布未知；真实 LLM A/B 仍为 null, 不以本地管道自检或 holdout 代替。来源键: metrics.software.unmeasured.online_ladder_games 来源键: metrics.software.unmeasured.online_skill_rating 来源键: metrics.software.unmeasured.llm_ab_win_rate

7.2 可复用资产

可复用资产包括: 候选 SHA 与冻结清单、AB/BA 调度、种子域隔离、异常 fail-closed、正式 export 事务发布、确认统计到 JSON Pointer 的追溯映射, 以及“新候选必须配新独立确认种子”的治理规则。

8 附录 A: 人机分工记录

环节	AI 辅助	人工责任
评估治理	实现并验证双座位、隔离、fail-closed 与 export 安全检查	审阅规则边界并裁决证据是否可用
策略修复	执行定向测试 35/35, 记录检查项	审阅行为变化并批准冻结
候选冻结	记录 SHA 7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a 与 git ref	确认该身份对应拟提交版本
一次性确认	执行既定协议并发布 attempt 1	确认不重跑、不重抽、不择优替换
文档	仅从 metrics 生成报告与 SOP v3	事实核对、审读与签字
线上操作	不登录、不提交、不代填未发生值	报名、提交、反馈回填和终交锁定

来源键: metrics.software.m2a_gate_contract_check_pass 来源键: metrics.software.m2a_export_safety_check_pass 来源键: metrics.software.strategy_repair_test_summary 来源键: metrics.software.frozen_candidate_identity 来源键: metrics.software.holdout_run_status

9 附录 B: 证据追溯与描述性 Elo

9.1 正式 export 追溯

项目	metrics 读取值
正式 export	workspace/software/exports/eval_results.json
export SHA-256	ac7684d853e368a26bf8685d6649d3d4d711a13a9eaacdadb6ff89c7aa5504f7
validated schema	2.0
候选身份	7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a
确认总体 JSON Pointer	/confirmatory/overall_record
逐对记录 JSON Pointer	/confirmatory/pair_records
座位记录 JSON Pointer	/confirmatory/seat_records
Wilson JSON Pointer	/confirmatory/wilson_intervals
成对统计 JSON Pointer	/confirmatory/order_independent_statistic
Elo JSON Pointer	/elo

来源键: metrics.software.confirmatory_export_traceability 来源键: metrics.software.frozen_candidate_identity

9.2 描述性 Elo 附录(不用于主结论)

该对象的角色标签为 descriptive_only, order_sensitive=true, k=32, start=1200。它只保留为复核 export 的描述性产物; 由于对局输入顺序会影响更新轨迹, 不用于候选确认、线上推断或版本门槛。来源键: metrics.software.confirmatory_elo_appendix

正式证据的唯一数据入口是 workspace/metrics.json; 其映射同时给出 export SHA、schema 和各确认性对象的 JSON Pointer, 从而避免从日志或旧报告手工抄值。