

Kaggriculture 农场博弈 Agent 战役 III

线上反馈重构报告 (m5 成稿)

document m5-redocument 成稿包 | 全部性能数字经 metrics 键引用渲染 | 数据源: workspace/metrics.json

1 摘要

本报告是战役 III (线上反馈重构版) 的 m5 成稿版。战役 II 建立的证据链——候选身份冻结、开发/确认种子隔离、AB/BA 双座位、异常 fail-closed、正式 export 原子发布与一次性独立 holdout——被战役 III 整体继承,并扩展到画像驱动的线上风格对手池。第一轮线上反馈(依赖真实线上提交,人工执行)在公共天梯留下 3 局台账战绩 1W-2L,其失利回放复盘产生的失败模式清单驱动了本战役的语料、对手池与候选重构。

metrics.software.unmeasured.online_ladder_games metrics.software.unmeasured.online_feedback_calibration

回放语料与画像管线落地官方 episodes 语料 60 局(异常剔除 0 局)、画像档案 120 份,原始回放字节量 1896052699 (合 1.9 GB),构建耗时 21.3 秒。

metrics.software.m1_corpus_episodes_total metrics.software.m1_corpus_abnormal_excluded metrics.software.m1_profiles_generated metrics.software.m1_download_bytes metrics.software.m1_corpus_runtime_seconds

四个画像参数化线上风格对手全部通过冻结弱池认证(各 12 局 12W-0L-0T),门禁必测名单由 4 个扩至 8 个(旧成员全保留),契约检查通过,对手单测 42 项与全量测试 246 项全部通过。

metrics.software.m2_online_style_opponents metrics.software.m2_opponent_pool_certification metrics.software.m2_gate_required_opponents

metrics.software.m2_gate_contract_check_pass metrics.software.m2_opponent_unit_tests_summary

市场自适应候选在含线上风格对手的完整开发门 64 局中取得 57W-7L-0T (异常 0 局),冻结身份 SHA-256 为 5713c17eadf1d026d2ccfbc2361bf65f

457e8d11843053c74fe4ec261a7a37ee。

metrics.software.m3_development_gate_summary metrics.software.m3_frozen_candidate_identity

一次性 holdout v2 (attempt 2) 与全部 38 个历史种子零交集,全池 576 局零异常;确认子集 128 局战绩 108W-20L-0T, score 0.84375, Wilson 95% 区间 [0.771, 0.8965];顺序无关成对估计 0.84375, Student-t 区间 [0.7551, 0.9324]。

metrics.software.m4_holdout_run_status metrics.software.m4_holdout_seed_domain_isolation metrics.software.m4_holdout_schedule metrics.software.m4_holdout_abnormal_summary

metrics.software.m4_confirmatory_overall_record metrics.software.m4_confirmatory_order_independent_statistics

上述本地结果绑定固定的本地 8 对手池,不外推为天梯实力、名次或获奖结论。逐对记录中 near_band_diversified 8W-8L-0T 与 template_wheat 10W-6L-0T 如实列为本候选在当前固定对手池上的短板。round-2 线上提交尚未发生,对应 unmeasured 子字段保持 null 如实渲染(见第 6、9 章)。前代 holdout 总体 score (0.929688) 保留为前代候选 (SHA 前缀 7c482921) 在固定对手池上的历史实测结论,受固定对手池分布偏移、不外推新候选限制约束(第 5 章)。

metrics.software.confirmatory_overall_record metrics.software.m2b_candidate_sha256

2 战役定位与范围

2.1 交付定位

战役 III 的目标是把第一轮线上反馈转化为可验证的重构:回放语料与画像管线、线上风格对手池、市场自适应候选引擎、一次性独立 holdout v2 与提交 SOP v4。可交付对象保持 stdlib-only、离线自包含 bot 与完整

证据链; 本波 (m5) 交付成稿包——本报告成稿、SOP v4 完整手册 (workspace/docs/sop-v4.md) 与 document 分片 metrics。账号报名、线上提交、Validation Episode 检查、round-2 采样与最终版本选择仍由队伍人工执行, 本报告不把流程约束写成已执行事实。

2.2 证据边界

战役 II 确认结果绑定前代候选 7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a, holdout 运行前、中、后哈希一致性判定为 true 战役 III 确认结果绑定候选 5713c17eadf1d026d2ccfbc2361bf65f

457e8d11843053c74fe4ec261a7a37ee, m4 holdout 的 frozen/before/after 一致性判定为 true。两代确认互不迁移: 任何策略或候选字节变化都构成新候选, 旧确认结果与旧 holdout 种子不得为新候选背书或复用。 metrics.software.m2b_candidate_sha256 metrics.software.holdout_candidate_hash_match metrics.software.m3_frozen_candidate_identity metrics.software.m4_holdout_candidate_hash_match

两代 holdout 种子均已在运行完成后公开: 战役 II 清单哈希 68292287a9b8254538f312fb6e3d1991ce215ca2ac2a4e4b0ecc51a6ddbdc93a, 战役 III 清单哈希 638fee9c0d1c1a3edc19cc61249b0f31fc290078d119f6582a4601a3620a8f44。公开后的这些种子不得再用于新的独立 holdout; 新候选必须冻结新身份并使用新的独立确认种子。 metrics.software.holdout_seed_manifest metrics.software.m4_holdout_seed_manifest

历史披露(仅此一处): 1500.8 / 36-0 属于固定 p0; 复用开发种子; 顺序敏感 Elo; 非确认性; 不可外推线上。该记录仅用于说明战役 II 审计为何重开, 不参与本报告主结论。 metrics.software.m2_elo_ratings_full_pool

2.3 禁止外推

本报告不把本地 holdout 等同于线上对手分布, 不对竞赛名次、奖项结果或线上能力作结论。第一轮线上证据样本极小且对手分布未知, 只用于失败模式复盘与画像设计输入; round-2 尚未发生, unmeasured.online_* 的 round-2 子字段保持未回填。LLM 真实 A/B 未发生, 对应值保持 null 预算闸真实触发值保持 null。 metrics.software.unmeasured.llm_ab_win_rate metrics.software.unmeasured.llm_ab_budget_gate_hits

3 方法与选型

3.1 候选身份锁定

战役 II: 开发门候选 SHA 与冻结 SHA 均为 7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a, holdout 三点哈希由正式 export 记录, 一致性判定 true。战役 III: 开发门候选 SHA 为 5713c17eadf1d026d2ccfbc2361bf65f457e8d11843053c74fe4ec261a7a37ee, 冻结身份含 manifest 与快照 (workspace/software/m3_frozen_manifest.json, 快照解码哈希 5713c17eadf1d026d2ccfbc2361bf65f457e8d11843053c74fe4ec261a7a37ee), m4 holdout 一致性判定 true。 metrics.software.development_gate_summary metrics.software.frozen_candidate_identity metrics.software.holdout_candidate_hash_match metrics.software.m3_development_gate_summary metrics.software.m3_frozen_candidate_identity metrics.software.m4_holdout_candidate_hash_match

3.2 种子域与一次性规则

战役 II 协议记录 one_time=true, candidate_change_invalidates=true, seed_count=8, 与历史种子交集 0, 隔离判定 true。战役 III 的 m4 协议同构: one_time=true, seed_count=8, 历史种子排除清单规模扩至 38 (覆盖战役 II 登记的开发/回归种子、已公布 holdout 种子与线上实测 episode 对应 seed), 交集计数 0, 隔离判定 true。 metrics.software.holdout_protocol metrics.software.holdout_seed_domain_isolation metrics.software.m4_holdout_protocol metrics.software.m4_holdout_seed_domain_isolation

种子只有在运行完成后公开。两代公开清单都是既有证据的一部分, 不再具备新独立确认集资格。

3.3 AB/BA 与完整矩阵

每个候选-对手-种子组合均以 AB/BA 镜像执行。战役 II 正式矩阵实际 576 局 (AB 288 / BA 288, 缺失镜像 0) ; 战役 III m4 正式矩阵实际 576 局 (AB 288 / BA 288, 缺失镜像 0)。 `metrics.software.holdout_schedule`
`metrics.software.holdout_seat_split metrics.software.m4_holdout_schedule metrics.software.m4_holdout_seat_split`

3.4 异常关闭与原子发布

生产契约检查判定为 true 它覆盖缺失必测对手、单座位、INVALID、畸形 tie、种子域不符和 exploratory 冒充正式 PASS 的拒绝路径。战役 III 在扩至 8 对手的必测名单上重跑同族检查, 判定为 true (含缺对手赛程与单座位赛程的拒绝复验, 以及战役 II 冻结 export 的 official 模式复验)。 `metrics.software.m2a_gate_contract_check_pass`
`metrics.software.m2_gate_contract_check_pass metrics.software.m2_gate_required_opponents`

export 安全检查判定为 true 正式结果只在 schema、语义和跨字段验证完成后发布, 开发或失败产物不得覆盖正式 export。 `metrics.software.m2a_export_safety_check_pass`

4 战役 II 四阶段波次执行记录

4.1 m2a: 评估器加固

完整软件测试通过 128/128 生产 gate 契约与 export 安全检查分别为 true 和 true。修复前的一次开发门已明确 `invalidated=true`, 不再作为合入证据。 `metrics.software.m2a_tests_passed`
`metrics.software.m2a_tests_total metrics.software.m2a_gate_contract_check_pass metrics.software.m2a_export_safety_check_pass`
`metrics.software.m2a_complete_gate_invalidated`

4.2 m2b: 策略修复与冻结

定向策略/契约测试通过 35/35, `failed=0`。检查项记录末日零资本支出=`true`、末日现收处置=`true`、购买观察确认=`true`、shed 库存预留=`true`、严格正数量=`true`。 `metrics.software.strategy_repair_test_summary`
`metrics.software.strategy_repair_checks`

完整开发门 `expected/actual` 为 32/32, AB/BA 为 16/16, 异常 0, 战绩 31W-1L-0T, `formal_pass=true`。通过后冻结候选 SHA-256 为 7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a。
`metrics.software.development_gate_summary metrics.software.frozen_candidate_identity`

4.3 m2c: 一次性独立 holdout

唯一记录的 `attempt index` 为 1, 状态 `published`, `published=true`, `invalidated=false`。正式全矩阵 `expected/actual` 为 576/576, 完整性合取判定为 `true`。 `metrics.software.holdout_run_status metrics.software.holdout_schedule`
`metrics.software.holdout_integrity_pass`

本阶段只发布既有 `attempt` 的结果。验证动作可以重读并校验正式文件, 但不得重跑、重抽或替换该 holdout。

4.4 m3: 文档重生成 (战役 II 收尾)

战役 II 收尾版只消费合并后的 `metrics`, 将旧开发 Elo 降为历史披露, 将主结论改为逐对 W/L/T、座位拆分、Wilson 区间和顺序无关成对统计。线上与真实 LLM A/B 的未测键继续显示 `null`。

5 战役 II 实测结果 (绑定前代冻结候选)

本章全部数字来自战役 II 正式 export, 绑定前代冻结候选 SHA-256 7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a。本章总体战绩与 `score` (119W-9L-0T, 0.929688) 是前代候选在战役 II 固定对手池上的一次性 holdout 实测历史结论: 固定

对手池分布偏移、不外推新候选、不外推线上,也不得迁移到战役 III 冻结候选 (5713c17e...) ; 战役 III 的现行结论以第 8 章为准。 `metrics.software.m2b_candidate_sha256` `metrics.software.confirmatory_overall_record` `metrics.software.m3_frozen_candidate_identity`

5.1 身份与完整性

审计项	结果
冻结候选 SHA-256	7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a
holdout 哈希一致	true
发布 attempt	index=1 status=published invalidated=false
完整矩阵 expected/actual	576 / 576
AB/BA; missing mirrors	288 / 288 0
异常局; integrity	0 true

`metrics.software.frozen_candidate_identity` `metrics.software.holdout_candidate_hash_match` `metrics.software.holdout_run_status` `metrics.software.holdout_schedule` `metrics.software.holdout_seat_split` `metrics.software.holdout_abnormal_summary` `metrics.software.holdout_integrity_pass`

5.2 总体与区间

冻结候选确认战绩为 119W-9L-0T, games=128, score=0.929688。 `metrics.software.confirmatory_overall_record`

统计量	估计	区间
逐局 score 的 Wilson 区间	0.929688	[0.8718, 0.9626]
每 (opponent, seed) AB/BA 成对均值; unit=64	0.929688	[0.867281, 0.992094]

`metrics.software.confirmatory_wilson_intervals` `metrics.software.confirmatory_order_independent_statistics`

Wilson 方法为 Wilson score; tie=0.5, confidence=0.95 成对统计方法为 mean per-(opponent,seed) AB/BA score; Student-t 95% CI, order_independent=true, fit_status=ok。 `metrics.software.confirmatory_wilson_intervals` `metrics.software.confirmatory_order_independent_statistics`

5.3 对手记录

opponent	games	W-L-T	score	Wilson interval
cow_baron	16	10W-6L-0T	0.625	[0.3864, 0.8152]
melon_hoarder	16	13W-3L-0T	0.8125	[0.5699, 0.9341]
expansionist	16	16W-0L-0T	1	[0.8064, 1]
baseline_wheat	16	16W-0L-0T	1	[0.8064, 1]
greedy_carrot	16	16W-0L-0T	1	[0.8064, 1]
starter	16	16W-0L-0T	1	[0.8064, 1]
random	16	16W-0L-0T	1	[0.8064, 1]
pass	16	16W-0L-0T	1	[0.8064, 1]

`metrics.software.confirmatory_pair_records`

5.4 座位记录

seat	games	W-L-T	score	Wilson interval
AB	64	60W-4L-0T	0.9375	[0.85, 0.9754]

seat	games	W-L-T	score	Wilson interval
BA	64	59W-5L-0T	0.921875	[0.8298, 0.9662]

metrics.software.confirmatory_seat_records

5.5 线上反馈与未回填项

指标	值	含义
round-1 线上对局	3	依赖真实线上提交, 已按第一轮实测回填
round-1 平台 skill rating	488.9	依赖真实线上提交与平台计分
round-1 反馈校准	1W-2L	第一轮失败模式台账见 exports/online/
round-2 公共战绩	null	round-2 尚未发生, 如实保持 null
round-2 采样台账	null	同上, 见 SOP v4 第 4 节
round-2 回拉复盘	null	同上, 见 SOP v4 第 6 节
止损状态	null	同上, 见 SOP v4 第 7 节
最终提交 commits	null	人工终交锁定尚未回填

metrics.software.unmeasured.online_ladder_games

metrics.software.unmeasured.online_skill_rating

metrics.software.unmeasured.online_feedback_calibration metrics.software.unmeasured.final_submission_commits

6 战役 III 线上反馈复盘 (round-1)

本章数字均为线上实测回填 (依赖真实线上提交与平台回放, 人工执行); 样本极小, 全章不外推。

6.1 公共局战绩与平台评分

第一轮提交 (依赖真实线上提交, 人工执行) 在公共天梯完成 3 局, 台账战绩 1W-2L, 平台 skill rating 快照为 488.9。逐局台账与分析文件路径由键内字段给出: workspace/software/exports/online/round1_ledger.json 与 workspace/software/exports/online/round1_failure_analysis.md。

metrics.software.unmeasured.online_ladder_games

metrics.software.unmeasured.online_skill_rating metrics.software.unmeasured.online_feedback_calibration

6.2 失败模式清单 (FM-O1..O4)

对第一轮公共局失利的回放复盘产生失败模式清单: FM-O1 portfolio concentration; FM-O2 no purchased-wheat feed; FM-O3 no high-value crops; FM-O4 CARE/DIG underuse。胜方呈现多元化经济结构, 与我方单一畜群结构形成对照; 这些失败模式构成本轮画像驱动重构的直接输入。

metrics.software.unmeasured.online_feedback_calibration

6.3 语料分层与画像输入

分层抽样以 2026-08-29 公共榜单为设计输入, 落地为四档语料: top-20 档 58 局、top-100 档 15 局、500-900 近段 2 局、我方基线 2 局 (单局可同时计入多档)。全榜排名与队伍总数快照没有 metrics 键, 本版不写数; 该快照只用作抽样设计输入, 不作名次结论。

metrics.software.ml_corpus_by_band

6.4 复盘进入战役 III 的链路

复盘结论按固定链路进入工程: 失败模式清单先行, 再定义画像维度 (资金曲线、畜群轨迹、作物轮替、雇佣强度、外购饲料、卖出价格门控、终局行为), 经跨局复核后参数化线上风格对手, 最终进入门禁与候选重构。同选手不少于 3 局一致才可作为对手参数依据; 单局结论一律标 exploratory。

7 战役 III 波次执行记录

本章记录 m1-m4 四个里程碑的实测落地; 全部数字经 metrics 键引用渲染, 无占位符残留。

7.1 m1: 回放语料与画像

官方 episodes index 解析与按需下载落地: 入库 60 局, 完整性校验 (双方 DONE、720 步) 后异常剔除 0 局, 逐局结构化画像 120 份 (每局两座位各一份), 原始回放字节量 1896052699 (合 1.9 GB, 原始回放仅落 gitignored 数据目录), 构建耗时 21.3 秒。分层构成见第 6.3 节。
metrics.software.m1_corpus_episodes_total metrics.software.m1_corpus_abnormal_excluded
metrics.software.m1_profiles_generated metrics.software.m1_download_bytes metrics.software.m1_corpus_runtime_seconds

画像层面对强段与基线的结构性差异形成多项一致发现: 强段雇佣强度更高、终局抛售占比更高、作物收入结构更多元、外购饲料与卖出价格门控更精细。带数字的参数依据只经 m2_online_style_opponents 键的 param_basis 字段进入本文 (见 7.2 节), 本节不另行罗列未经键化的数字。

7.2 m2: 线上风格对手池

依据跨局复核后的画像参数实现四个线上风格对手 (主打 bot 只用同选手不少于 3 局一致发现; near_band_diversified 显式 exploratory) :

- **crop_rotator** — 原型 Crop Dusta (rank 1) 画像档案 5 份; exploratory=false
- **template_wheat** — 原型 NiklitaCheporev(8 局)/Multi-Head Farmers(6 局)/Aashka Kapadia(3 局)/Gaddam Shiva Teja(3 局)/Levin(3 局)/heralces(3 局) 同构模板集群 画像档案 6 份; exploratory=false
- **self_feed_ranch** — 原型 Milan Leonard (rank 2) 画像档案 3 份; exploratory=false
- **near_band_diversified** — 原型 Sooriya Senthilkumar (rank 3629) / Chirag Bhatnagar (rank 3978) 画像档案 2 份; exploratory=true

参数依据 (键内 param_basis 字段) : 同选手 >=3 局一致画像: 26 局 (雇佣 9.7-9.9/天、3 象限、7 牛 4 羊 1 鹅、小麦占比 20-69% 波动、外购饲料 506-2732u@均价 34-39); 同选手 >=3 局一致画像: 外购饲料 414-436u 恒定、小麦田 42% 恒定、雇佣 9.4/天、终群 8 牛 4 羊; 同选手 >=3 局一致画像: 12 局 (外购饲料仅 119-147u、小麦 43-50%、雇佣 8.9-9.3/天、奶卖价中位 200/毛 220、外购肥料 31u); exploratory: 仅 2 局 (每选手 1 局), 但两名独立选手结构收敛 (草莓 51.8%/33.7% 主导 + 7-8 牛混合群 + 终局卖出占比 12.6-17.7%); 按蓝图 m2 以真实线上分布代表性纳入 metrics.software.m2_online_style_opponents

认证 (对冻结弱池, 阈值 0.5) : 四个线上风格对手与三个强族对手全部达标, threshold_met_by_all=true。

metrics.software.m2_opponent_pool_certification

对手	games	W-L-T	win_rate	vs greedy_carrot 均差
crop_rotator	12	12W-0L-0T	1	57035
template_wheat	12	12W-0L-0T	1	55071
self_feed_ranch	12	12W-0L-0T	1	66649
near_band_diversified	12	12W-0L-0T	1	59625
12 (强族复认证)	—	12W-0L-0T	1	—

metrics.software.m2_opponent_pool_certification

门禁必测名单由 4 个 (cow_baron, melon_hoarder, expansionist, baseline_wheat) 扩至 8 个 (新增 crop_rotator, template_wheat, self_feed_ranch, near_band_diversified), 旧成员全保留 (old_members_retained=true), 名单哈希 14dcaea76e02cfae963d0a7299ae6f2d

758f226b7af865beeed063054b76395c, 完整门预期 64 局; 缺失必测对手与单座位赛程均被契约检查拒绝 (missing_opponent_schedule_rejected=true)。对手单测 42/42, 全量测试 246/246 覆盖面: 契约(合法动作/确定性/敌意 obs/短局); exploratory 标志纪律; 雇佣节律(象限缩放/日斜坡); 轮作触发(价格门+相位窗); 外

购饲料护栏(价格上限+晨间配给+gap 模式); 卖出门(持有/释放/倾销); 终局倾销窗口(day27/28); 象限扩张时机; 畜群构成。 `metrics.software.m2_gate_required_opponents metrics.software.m2_opponent_unit_tests_summary`

7.3 m3: 市场自适应候选与冻结

候选引擎按画像发现重构: 轮作触发与价格下限、外购饲料护栏、劳动扩容强度、第三象限扩张、终局囤积-倾销与末日停喂、死价格冻结泛化, 并保留 m2b 全部修复不回退。分项能力回归判定:

能力组 (键内字段)	verdict	tests
rotation_trigger_and_price_floors	pass	4
external_feed_guardrail	pass	3
labour_expansion_intensity	pass	3
third_quadrant_expansion	pass	4
endgame_hoard_dump_and_stop_feed	pass	5
dead_price_freeze_generalized	pass	3
m2b_fixes_no_regression	pass	26

`metrics.software.m3_strategy_capability_checks`

策略回归: m3 新增测试 23/23, m2b 保留测试 26/26, 完整套件 269/269。

`metrics.software.m3_strategy_regression_summary`

完整开发门 (8 必测对手 x seeds 101-102-103-104 x AB/BA = 64 局, expected 64) : 战绩 57W-7L-0T, AB/BA 32/32, 异常 0, formal_pass=true, 耗时 276.42 秒。逐对开发门记录:

opponent	W-L-T	win_rate	avg_margin
cow_baron	8W-0L-0T	1	24293
melon_hoarder	8W-0L-0T	1	44330.6
expansionist	8W-0L-0T	1	63371.2
baseline_wheat	8W-0L-0T	1	71261.8
crop_rotator	8W-0L-0T	1	10216.8
template_wheat	8W-0L-0T	1	5195
self_feed_ranch	5W-3L-0T	0.625	-397.6
near_band_diversified	4W-4L-0T	0.5	1648.1

`metrics.software.m3_development_gate_summary`

开发门内 self_feed_ranch 与 near_band_diversified 已接近持平, 该信号在 m4 holdout 中进一步显现 (第 8 章)。通过后冻结候选身份: 路径 workspace/software/kaggle_simulations/agent/main.py, SHA-256 5713c17eadf1d026d2ccfbc2361bf65f

457e8d11843053c74fe4ec261a7a37ee, git ref b47bc16f426fbfeeab645e86a5b4453d45b5779a, manifest workspace/software/m3_frozen_manifest.json (SHA-256 67e08238e44b7c76a262f34baea27fe6 c721bfb545cacb0fe239a6c76a6d3b2a) , 快照 workspace/software/m3_frozen_candidate.b64。

`metrics.software.m3_frozen_candidate_identity`

7.4 m4: 一次性独立 holdout v2

m4 协议: one_time=true, candidate_change_invalidates=true, seed_count=8, 历史种子排除清单 38 个; 种子在冻结后生成、运行完成后公开, manifest SHA-256 为 638fee9c0d1c1a3edc19cc61249b0f31fc290078d119f6582a4601a3620a8f44 (attempt b75258615f75baf54275ff54) , 与历史种子交集 0, 隔离判定 true。候选哈

希 三 点 一 致 判 定 `true`。`metrics.software.m4_holdout_protocol` `metrics.software.m4_holdout_seed_manifest`
`metrics.software.m4_holdout_seed_domain_isolation` `metrics.software.m4_holdout_candidate_hash_match`

运行状态: `attempt index 2, status=published, published=true, invalidated=false` 此前 `attempt 1` 的证据保留于 `workspace/software/exports/holdout/attempt-1`。运行工作区状态与输入闭包哈希由键内 `worktree_state` 注记 (边界外零改动)。完整矩阵 `expected/actual 576/576, AB/BA 288/288 (缺失镜像 0)`, 异常局 `0`, 完整性合取判定 `true`。`metrics.software.m4_holdout_run_status`
`metrics.software.m4_holdout_schedule` `metrics.software.m4_holdout_seat_split` `metrics.software.m4_holdout_abnormal_summary`
`metrics.software.m4_holdout_integrity_pass`

8 战役 III 实测结果 (m4 holdout v2, 绑定 m3 冻结候选)

本章数字绑定战役 III 冻结候选 SHA-256 5713c17eadf1d026d2ccfbc2361bf65f457e8d11843053c74fe4ec261a7a37ee, 对手池为 m2 扩展后的 8 个必测对手。全部结论仅在本地官方引擎与该固定对手池上成立, 不外推为天梯实力、名次或获奖结论。`metrics.software.m3_frozen_candidate_identity`
`metrics.software.m3_development_gate_summary`

8.1 总体与区间

冻结候选确认战绩为 108W-20L-0T, games=128, score=0.84375。`metrics.software.m4_confirmatory_overall_record`

统计量	估计	区间
逐局 score 的 Wilson 区间	0.84375	[0.771, 0.8965]
每 (opponent, seed) AB/BA 成对均值; unit=64	0.84375	[0.7551, 0.9324]

`metrics.software.m4_confirmatory_wilson_intervals` `metrics.software.m4_confirmatory_order_independent_statistics`

Wilson 方法为 Wilson score; tie=0.5, confidence=0.95 成对统计方法为 mean per-(opponent,seed) AB/BA score; Student-t 95% CI, order_independent=true, fit_status=ok。`metrics.software.m4_confirmatory_wilson_intervals`
`metrics.software.m4_confirmatory_order_independent_statistics`

8.2 对手记录

opponent	games	W-L-T	score	Wilson interval
cow_baron	16	16W-0L-0T	1	[0.8064, 1]
melon_hoarder	16	16W-0L-0T	1	[0.8064, 1]
expansionist	16	16W-0L-0T	1	[0.8064, 1]
baseline_wheat	16	16W-0L-0T	1	[0.8064, 1]
crop_rotator	16	12W-4L-0T	0.75	[0.505, 0.8982]
template_wheat	16	10W-6L-0T	0.625	[0.3864, 0.8152]
self_feed_ranch	16	14W-2L-0T	0.875	[0.6398, 0.965]
near_band_diversified	16	8W-8L-0T	0.5	[0.28, 0.72]

`metrics.software.m4_confirmatory_pair_records`

逐对记录如实呈现: 对 cow_baron、melon_hoarder、expansionist、baseline_wheat 四对全胜 (各 16 局), crop_rotator 12W-4L-0T, self_feed_ranch 14W-2L-0T near_band_diversified 8W-8L-0T 胜负各半、template_wheat 10W-6L-0T 接近持平, 如实列为本候选在当前固定对手池上的短板, 是 round-2 复盘与候选迭代的首要输入。本章全部数字不外推为天梯实力、名次或获奖结论。

与前代总体 score (0.929688) 的对照仅作审计叙事: 两代数字分别绑定不同候选与不同固定对手池 (战役 II 池不含线上风格对手), 对手池分布偏移使二者不构成跨池可比的能力结论, 互不外推、互不迁移。`metrics.software.confirmatory_overall_record`

8.3 座位记录

seat	games	W-L-T	score	Wilson interval
AB	64	55W-9L-0T	0.859375	[0.7538, 0.9242]
BA	64	53W-11L-0T	0.828125	[0.7179, 0.9012]

`metrics.software.m4_confirmatory_seat_records`

8.4 描述性 Elo 附录 (不用于主结论)

该对象角色标签为 `descriptive_only`, `order_sensitive=true`, `k=32`, `start=1200` 候选条目 rating 1349 (played 128)。由于对局输入顺序影响更新轨迹, 该表不用于候选确认、版本门槛或任何线上推断。`metrics.software.m4_confirmatory_elo_appendix`

9 提交 SOP v4 要点

本节只收录操作约束要点; 完整手册见 `workspace/docs/sop-v4.md` (V4-01..V4-44 检查项成稿)。以下均为流程约束, 不是已执行声明; 额度与阈值 (每日提交 ≤ 5 次、每候选 ≤ 2 次/日、每轮回拉 ≥ 3 局、公共局累计 ≥ 6 局且胜率低于 50%) 是蓝图契约常量, 不是实测数字。

9.1 权威身份门

SOP v4 以战役 III 冻结候选 SHA (前缀 5713c17e) 与 m4 正式 export 身份 (schema 2.0, SHA-256 a87bc26e285722b14d85b5012b3da87b142a7e9b8680527fc0ecb0ea44de0404) 为提交前检查门的权威值, 从 `metrics` 读取、不以旧报告抄值; 战役 II 身份整段降级为历史记录, 不得为新候选背书。`metrics.software.m3_frozen_candidate_identity`
`metrics.software.m4_confirmatory_export_traceability`

9.2 round-2 天梯采样-回拉-复盘循环

- 每日提交至多 5 次; 每候选至多 2 次/日; 提交前核对当日额度与「最近 2 次提交」跟踪, 新提交不得无意覆盖应保留版本。
- Validation Episode 返回 Error 即停当日提交并上报, 不得以连续重试掩盖错误。
- 每次提交后回拉不少于 3 局公共天梯回放完成复盘, 更新失败模式台账 (延续 FM-O 编号族) 并滚动更新画像档案; 复盘产出按第 6 章链路进入对手池参数与新候选规则。
- 台账逐次对接 `unmeasured.online_feedback_calibration` 的 round-2 子字段; 当前这些子字段保持 null (依赖真实线上提交, 人工执行)。

9.3 止损线与转备选

- 触发条件: 新候选线上公共局累计不少于 6 局且胜率低于 50%; 触发后禁止继续本方向调参, 转备选方向接力, 判定与动作记录入 `stop_loss_status` 子字段并上报队伍。
- 止损是资源分配决策, 不外推为任何线上实力、名次或获奖结论。

10 合规与人机分工

10.1 合规边界

提交 bot 保持离线、自包含和 `stdlib-only`; 外部 LLM 不是线上运行依赖。回放画像与线上复盘只用于离线设计, 提交 bot 不依赖外部数据集、LLM 或网络 API。正式结论只消费身份匹配、完整矩阵、零异常且已

发布的 export。账号报名、提交、Validation Episode 检查、round-2 采样、提交额度管理和最终锁定均由队伍人工执行,本报告不把流程约束写成已完成事实。

10.2 人机分工概要

AI 辅助完成评估器加固、策略修复、测试与本地证据生成,并依据 metrics 重写文档;战役 III 中另承担语料画像、线上风格对手实现、候选重构与本成稿文档。人工负责规则复核、候选裁决、Kaggle 账号操作、线上反馈解释、round-2 采样与止损裁决以及最终签字。详细留痕见附录 A。

11 遗留与可复用资产

11.1 局限

- 当前确认集对手来自既定本地 8 对手池,不能覆盖未知线上策略分布;near_band_diversified 与 template_wheat 两对短板如实保留 (第 8 章)。metrics.software.m4_confirmatory_pair_records
- 两代 holdout 种子均已公开,只能复核既有证据,不得再作为新独立确认集。metrics.software.holdout_seed_manifest metrics.software.m4_holdout_seed_manifest
- 任何策略变化都会使旧候选身份与确认结果不再适用于新候选。metrics.software.m4_holdout_protocol
- round-2 线上提交尚未发生,unmeasured.online_* 的 round-2 子字段与最终提交 commits 保持 null,不以本地管道自检或 holdout 代替。metrics.software.unmeasured.online_ladder_games metrics.software.unmeasured.online_skill_rating metrics.software.unmeasured.final_submission_commits
- 真实 LLM A/B 仍未发生,对应键保持 null。metrics.software.unmeasured.llm_ab_win_rate
- 全榜排名与队伍总数快照没有 metrics 键,本版不写数 (第 6.3 节)。

11.2 可复用资产

可复用资产包括: 候选 SHA 与冻结清单 (manifest + 字节级快照)、AB/BA 调度、种子域隔离、异常 fail-closed、正式 export 事务发布、确认统计到 JSON Pointer 的追溯映射,以及「新候选必须配新独立确认种子」的治理规则。战役 III 在其上追加: 带来源标注的回放画像档案、画像参数化线上风格对手池、必测名单哈希门,以及 round-2 天梯采样-回拉-复盘循环与止损线 (SOP v4)。

12 附录 A: 人机分工记录

环节	AI 辅助	人工责任
评估治理	实现并验证双座位、隔离、fail-closed 与 export 安全检查	审阅规则边界并裁决证据是否可用
策略修复	执行定向测试 35/35, 记录检查项	审阅行为变化并批准冻结
候选冻结	记录战役 II/III SHA 与 git ref	确认该身份对应拟提交版本
一次性确认	执行既定协议并发布战役 II attempt 1 与战役 III attempt 2	确认不重跑、不重抽、不择优替换
回放语料与画像	解析 index、下载 1896052699 字节、画像提取 120 份与完整性校验	抽查档案来源标注并裁决画像可用性
线上风格对手池	实现 4 个风格 bot 并执行弱池认证与 42 项单测	审阅画像参数并裁决对手入库
候选重构	实现轮作、畜群、饲料、劳动、象限与终局能力及 269 项套件	审阅行为变化并批准新候选冻结
线上反馈复盘	整理 round-1 台账与 FM-O 清单,维护 round-2 采样额度台账接口	提交、回拉回放、复盘解释与止损裁决
文档	仅从 metrics 生成报告成稿与 SOP v4	事实核对、审读与签字
线上操作	不登录、不提交、不代填未发生值	报名、提交、反馈回填和终交锁定

```
metrics.software.m2a_gate_contract_check_pass metrics.software.m2a_export_safety_check_pass
metrics.software.strategy_repair_test_summary metrics.software.frozen_candidate_identity metrics.software.holdout_run_status
metrics.software.m1_profiles_generated metrics.software.m2_online_style_opponents
metrics.software.m2_opponent_unit_tests_summary metrics.software.m3_strategy_regression_summary
```

13 附录 B: 证据追溯与描述性 Elo

13.1 正式 export 追溯（两代）

项目	metrics 读取值
战役 II 正式 export	workspace/software/exports/eval_results.json
战役 II export SHA-256	ac7684d853e368a26bf8685d6649d3d4d711a13a9eaacdadb6ff89c7aa5504f7
战役 II validated schema	2.0
战役 II 候选身份	7c482921857562e6b7cd58a3ac4bde358981c180cc233ad3913948e5fcafa66a
战役 II 确认总体 Pointer	/confirmatory/overall_record
战役 II 逐对/座位/Wilson/成对/Elo Pointer	/confirmatory/pair_records /confirmatory/seat_records /confirmatory/wilson_intervals /confirmatory/order_independent_statistic/elo
战役 III 正式 export	workspace/software/exports/eval_results.json
战役 III export SHA-256	a87bc26e285722b14d85b5012b3da87b142a7e9b8680527fc0ecb0ea44de0404
战役 III validated schema	2.0
战役 III 候选身份	5713c17eadf1d026d2ccfbc2361bf65f457e8d11843053c74fe4ec261a7a37ee
战役 III 确认总体 Pointer	/confirmatory/overall_record
战役 III 逐对/座位/Wilson/成对/Elo Pointer	/confirmatory/pair_records /confirmatory/seat_records /confirmatory/wilson_intervals /confirmatory/order_independent_statistic/elo

```
metrics.software.confirmatory_export_traceability metrics.software.m4_confirmatory_export_traceability
```

13.2 描述性 Elo 附录（战役 II, 不用于主结论）

战役 II 该对象角色标签为 descriptive_only, order_sensitive=true, k=32, start=1200。它只保留为复核 export 的描述性产物; 由于对局输入顺序会影响更新轨迹, 不用于候选确认、版本门槛或任何线上推断。

```
metrics.software.confirmatory_elo_appendix
```

正式证据的唯一数据入口是 workspace/metrics.json; 其映射同时给出两代 export SHA、schema 和各确认性对象的 JSON Pointer, 避免从日志或旧报告手工抄值。文档侧的核对入口为 m("confirmatory_export_traceability") 与 m("m4_confirmatory_export_traceability") 两个键; 战役 III 新增键的需求与回填对照见 metrics-keys-r3.md。